

研究標題：正豪智多星—基於檢索增強生成 (RAG) 之教授資訊問答系統，幫助你了解你不知道的正豪

組員：112340104 黃紹泓、112590005 陳宇威

研究內容、作法：

對王正豪教授之個人 GitHub Pages 建立一套「學術資訊索引與問答導航系統」。本系統不採取傳統的文件全解析路徑，而是透過自動化技術將教授網路上零散的英文學術著作清單、研究簡歷與個人成就，轉化為具備語意關聯的結構化向量知識庫。

核心作法側重於「混合檢索 (Hybrid Search)」、「意圖路由」與「精準溯源」：

資料前處理：系統透過通用 Markdown 爬蟲抓取網頁文本，保留多重年份的原始 URL 結構，並輔以實體擴充 (Entity Augmentation) 與 Metadata 標籤化。

意圖路由與混合檢索：當使用者提出中文問題時，系統先透過大語言模型 (LLM) 判斷查詢意圖並提取關鍵字，隨後啟動「BM25 稀疏檢索 (精確字串)」與「E5 稠密向量檢索 (跨語言語意)」雙引擎，利用 RRF (倒數秩融合) 演算法找出最精準的資訊片段。

防幻覺機制：系統被嚴格限定僅能根據檢索到的學術資料回答。若檢索信心分數低於門檻，或資料庫僅包含論文/課程標題而無實體內文，系統將主動提供原始網頁連結引導使用者自行閱讀，堅決杜絕 AI 憑空杜撰，確保提供最權威、最真實的「正豪資訊」。

NLP 單元技術使用：

- **Ch.2 Words and Tokens**

應用於爬蟲後的資料清洗、Markdown 格式輕量化，以及在實作 BM25 稀疏檢索 (Sparse Retrieval) 時，處理中英文混合文本的 Tokenization 與斷詞優化，確保精確關鍵字 (如年份、專有名詞) 的匹配率。

- **Ch.5 Embeddings**

系統核心技術。捨棄傳統單語系模型，採用跨語言句向量模型，將教授全英文相關資訊轉化為高維度語意向量，完美實現「中文提問、英文檢索」的跨語言語意搜尋基礎。

- **Ch.7 Large Language Models (LLMs)**

在本專案中扮演「中介大腦」與「生成器」雙重角色。前端利用 LLM 解析使用者口語提問，去除無意義語助詞並萃取檢索條件（Query Rewriting）；後端則利用其強大的自然語言生成能力，將零碎的 Markdown 片段與連結整合成人類可讀、有禮貌且精準的回答。

- **Ch.8 Transformers (Introduction)**

理解並應用基於 Transformer 架構的預訓練模型技術。本專案所依賴的 Embedding 向量化模型及後端生成 LLM，皆是建立在此架構之上，以確保能處理學術資料的長文本與複雜上下文關係。

- **Ch.17 Sequence Labeling (NER) / Information Extraction**

系統在建立層次化索引時，透過自動化資訊抽取技術（Information Extraction），從教授的個人簡介與清單中提取「課程名稱」、「年份」、「資料類型（大綱或摘要）」等關鍵實體（Entities），轉化為關聯式 Metadata，優化後續檢索過濾（Metadata Filtering）的品質。